

数据库AIOps---基于算法的IT运维

算法+海量运维数据+经验

数据库AIOPS运维

通过算法从海量运维数据中学习摸索规则，逐步降低对人指定规则的依赖，进而减少人为失误，提高运维效率。



数据变化量预测

提取海量运维监控数据的时序特征并结合异常值检测、时序回归算法对数据增长量进行预测。

数据库参数自动调优

对海量数据库性能指标数据运用算法进行机器学习，得到不同负载场景下的参数模型，能快速、高效的为DBA提供评估建议。可应用在新系统选型、数据库参数预配置、调优等场景。

异常值检测

腾讯开源的Metis时间序列异常检测学件。基于统计判决、无监督和有监督学习对时序数据进行联合检测。通过统计判决、无监督算法进行首层判决，输出疑似异常，其次进行有监督模型判决，得到最终检测结果

数据变化量预测

以预测Oracle数据库的表空间数据增长量与变化量为训练场景，收集数据库性能指标数据，在进行数据清理、格式化后，运用多种数据分析手段对原始数据进行分析、聚类 and 异常值检测。通过对整理分析过的数据进行机器学习算法训练，得到能够准确进行预测的模型。

01



数据采集

- 定时采集特征数据
- 163维数据库特征

02



数据预处理

- 数据清洗、格式化。包括缺失值、无效值等的处理，格式化成熟矩阵形式方便后续算法进行调用

03



因子分析

- 采用因子分析进行数据特征的探索。将原始变量简化为更小的一组因子并捕获原始变量之间的相关模式

04



特征聚类

- 采用降维算法-Kmeans++对数据特征做降维处理、分析，得到几个大的类集群。大幅降低数据特征的数量。

05



数据异常检测

- 采用腾讯开源的Metis学件进行时序数据异常检测。找出异常点进行标注，用于之后的预测分析

06



模型训练、预测

- 分别采用ARIMA算法、Adaboost算法、循环神经网络LSTM、Ridge回归算法分别进行模型训练，最终选取最优模型进行预测

○ 数据变化量预测

下图是经过降维算法处理之后的Oracle数据库性能负载数据特征，数据集容量只采集了68个时间点（每小时采集一次）的系统性能负载数据。降维聚类后的特征与DBA用经验判断与数据变化量相关的特征相比，大部分能够吻合。随着训练数据集的大小和特征场景的不断丰富，降维聚类后的数据特征会更加紧接甚至好于经验丰富的DBA的判断结果。

红色标出的特征跟数据量变化非常紧密。

≡ 系统负载分析平台




2019-08-07 09:33 得到['CR Undo Records Applied Per Sec', 'Cell Physical IO Interconnect Bytes', 'Physical Read Total Bytes Per Sec', 'Total PGA Allocated', 'Temp Space Used', 'Total PGA Used by SQL Workareas', 'Physical Write Bytes Per Sec', 'Physical Write Total Bytes Per Sec', 'Redo Generated Per Sec', 'Physical Read Bytes Per Sec', 'Logical Reads Per Sec', 'Redo Generated Per Txn', 'Physical Reads Direct Per Sec', 'I/O Requests per Second', 'Rows Per Sort', 'Consistent Read Gets Per Sec', 'DB Block Gets Per Sec', 'Cursor Cache Hit Ratio', 'Physical Reads Per Sec', 'DB Block Changes Per Sec']
聚类结果

数据变化量预测

模型预测对比结果

经过模型评价指标R2和RMSE评估，ARIMA的模型预测效果优于其他机器学习算法模型。Adaboost集成学习算法效果也还不错，LSTM卷积网络表现差一些。毕竟神经网络主要用图像、语音等场景的处理。整个预测流程和算法都需要进一步改进；改进测试数据集的质量和加大规模，训练效果会更好。

ARIMA预测效果




ARIMA
时序回归

从回归算法的评估指标来看，ARIMA+时间序列异常预测效果最好，使用的评价指标为**R2Score=0.87**（拟合优度，越接近1，表明模型越好）和**RMSE均方误差根=110.2**（预测值与真实值的误差平方根的均值）。

```
已迭代48次（共10次）
已迭代49次（共10次）
已迭代50次（共10次）
/usr/local/lib/python3.6/dist-packages/sklearn/model_selection/_split.py:2179: FutureWarning: From versior
d.
FutureWarning)
-2.526523800982941
Ridge回归树模型的R^2值为： -0.008645518688012999
Lasso with FA and K-means features 123988105.4334258 11134.994631046115
AdaBoost回归树模型的R^2值为： 0.7814327485380117
RNN的LSTM的R^2值为： 0.6306960559853058
[09/Aug/2019 23:41:33] "GET /metric_process/spacechange_trend/ HTTP/1.1" 200 44464
```

Adaboost预测效果

空间容量变化量预测-AdaBoost



Adaboost
集成算法

本次测试基于决策树回归的弱学习器，集成学习Adaboost的随机预测效果基本符合真实值变化趋势。R2 Score 为0.78。图中红框部分拟合效果还是不错的。

```
# 弱回归
dt_stump = DecisionTreeRegressor(max_depth=10)
# AdaBoost 回归
ada = AdaBoostRegressor(base_estimator=dt_stump, n_estimators=n_estimators, random_state=1, learning_rate=0.001)
```

数据变化量预测

已迭代 48次 (共10次)
已迭代 49次 (共10次)
已迭代 50次 (共10次)
/usr/local/lib/python3.6/dist-packages/sklearn/model_selection/_split.py:2179: FutureWarning: From versior
d.
FutureWarning)
-2.526523800982941
Ridge回归树模型的R^2值为: -0.008645518688012999
Lasso with FA and K-means features 123988105.4334258 11134.994631046115
AdaBoost回归树模型的R^2值为: 0.7814327485380117
RNN的 LSTM 的 R^2值为: 0.6306960559853058
[09/Aug/2019 23:41:33] "GET /metric_process/spacechange_trend/ HTTP/1.1" 200 44464

LSTM预测效果

空间容量变化量预测-LSTM



基于Keras框架的LSTM循环神经网络预测效果也基本符合真实值变化的趋势。图中红框的预测差异大。R2 Score 为 0.63


```
# RNN网络进行预测 LSTM
from keras.models import Sequential
from keras.layers import LSTM, Dense

x_train_rnn, x_test_rnn, y_train_rnn, y_test_rnn = train_test_split(space
                                                                    train
ss = MinMaxScaler(feature_range=(-1, 1))
```

神经网络
LSTM

Ridge预测效果

空间容量变化量预测-RIDGE



Ridge回归

Ridge回归预测的R2 Score为0.008。且预测出现了负值。效果不好

数据变化量预测

◆ ARIMA算法:

差分自回归移动平均模型。是用于时间序列分析的算法。原理是将非平稳时间序列转换为平稳时间序列然后将因变量仅对它的滞后值以及随机误差项的现值和滞后值进行回归所建立的模型。是时间序列分析中常用的算法模型。

AR是自回归。MA是移动平均。

三个参数: p为自回归项q为移动平均数。d为时间序列成为平稳时所做的差分次数

◆ Metis时间序列异常检测学件。

由腾讯开源出来的机器学习学件。时间序列异常检测学件的实现思路是基于统计判决、无监督和有监督学习对时序数据进行联合检测。通过统计判决、无监督算法进行首层判决, 输出疑似异常, 其次进行有监督模型判决, 得到最终检测结果。检测模型是经大量样本训练生成, 可根据样本持续训练更新。

◆ TSFRESH时间序列特征提取库

很有用的时间序列特征提取库, 一共有100+时间特征可以使用。在Metis中使用了30多种时序特征。TSFRESH自动从时间序列中提取100多个个特征。这些特征描述了时间序列的基本特征, 如峰值的数量、平均值或最大值或更复杂的特征, 如时间反转对称统计量。

GITHUB地址: <https://github.com/blue-yonder/tsfresh>。

◆ 线性回归

RIDGE: 用于共线性数据分析的回归方法, 用最小二乘线性回归来估计。也叫先验分布为高斯分布的贝叶斯估计

LASSO: 用于共线性数据分析的回归方法, 用最小二乘线性回归来估计, 也叫先验分布为拉普拉斯分布的贝叶斯估计。

◆ 因子分析

用于研究观测变量变动的共同原因和特殊原因, 从而达到简化变量结构的多元统计分析方法。两个方面, 以寻求变量的基本结构, 简化变量系统, 二是用于分类。

◆ K-Means聚类

基于距离、相似度的聚类算法。基本步骤如下:

- 1 给定数据
- 2 确定类别数, 并初始化K个类的中心
- 3 对每个数据点, 计算离其最近的类。
- 4 多每个类, 计算其所有数据的中心, 并更新为新的中心
- 5 重复3-4步。知道数据点所属类别类不再改变

◆ Adaboost算法

Boosting算法就是将弱学习器组合成强的分类器或者回归算法。没有先验知识的情况下, 初始的分布为等概分布, 即训练集如果有N个样本, 每个样本的分布概率为1/N。每次循环后提高误分样本的分布概率, 误分样本在训练集中所占权重增大, 使得下一次循环的弱学习器能够集中力量对这些误分样本进行判断

数据库参数自动调优---OTTERTUNE

Ottertune是卡内基梅隆大学数据库小组利用机器学习对数据库的参数进行自动化的调优，它能利用已有的数据训练机器学习模型，进而对待评估的系统自动化的推荐最优参数，它能很好的协助DBA进行数据库调优，同时也能为新系统选型、数据库参数预配置等提供有价值的建议。在原有的开源版本基础上我加入了Oracle的参数调优部分。目前仅支持Oracle单实例。Oracle采集性能指标特征163个。Mysql采集性能指标特征356个。Oracle RAC架构的预测功能计划后续开发。目前单实例预测的效果和原著论文里的评价标准基本吻合。



01.数据采集、上传

- 配置数据源和性能指标
- 定时采集数据库参数和性能指标数据
- 支持单个或批量上传采集数据到服务端

02.数据清洗

- 数据清洗、格式化。包括缺失值、无效值等的处理，格式化成多维矩阵，作为后续算法的输入。

03.参数特征处理

- 采用降维算法修剪冗余指标，确定关键数据库参数指标

04.性能指标特征处理

- 采用聚类分析算法对性能指标数据进行分析，修剪冗余指标。确定关键性能指标数据特征。

05.负载匹配

- 采用计算相似度算法—欧式距离从系统负载特征库中找到与待评估系统负载最为相似的工作负载，

06.调优建议

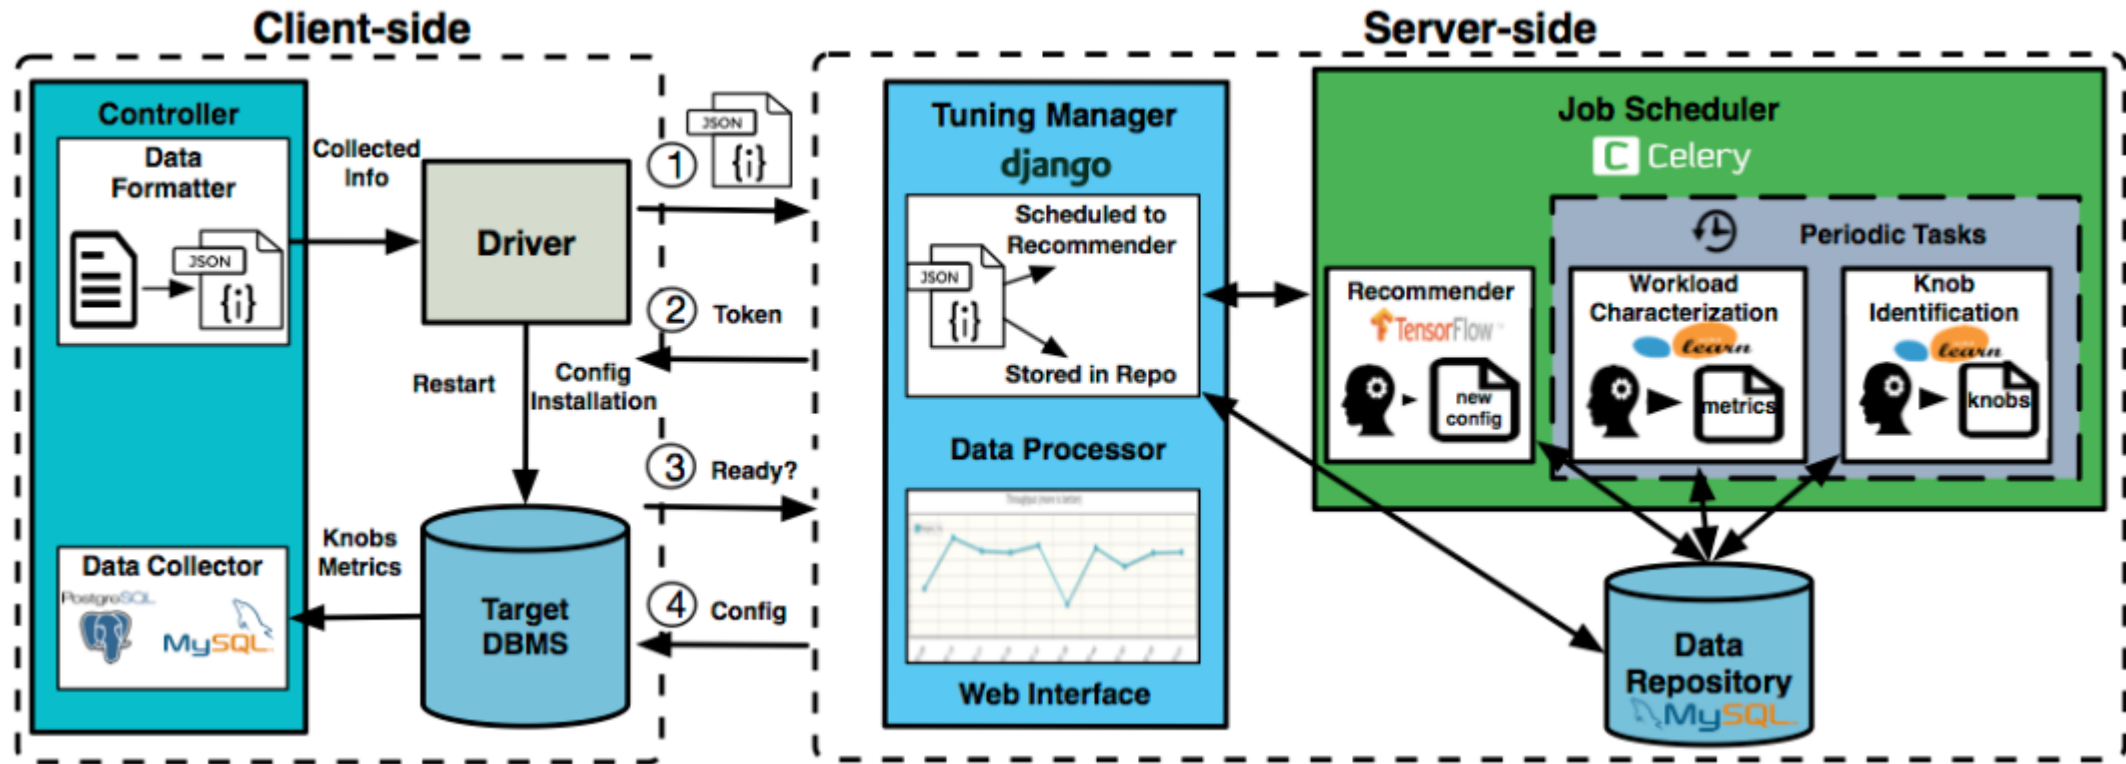
- 利用高斯过程来预测待评估系统主要参数指标的设置建议，在评估过程中会加入相关噪声数据使得评估建议更加准确。

GitHub地址: <https://github.com/cmu-db/ottertune>

数据库参数自动调优---OTTERTUNE

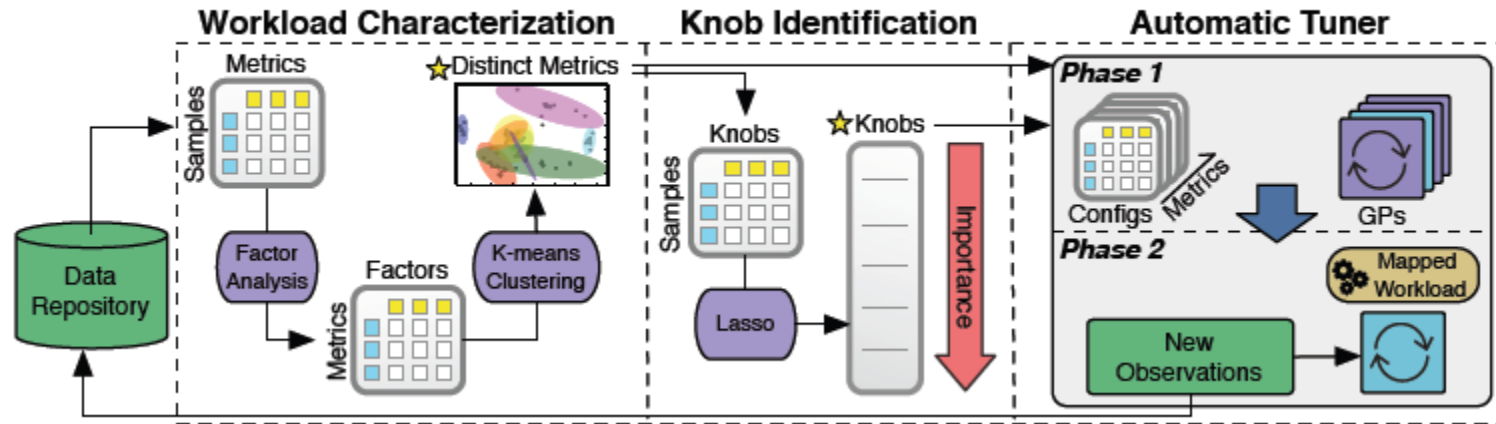
OtterTune系统架构图

OtterTune采用C/S模式。Client端负责采集数据库参数数据和数据库性能指标数据，并导入到系统资料库中。Client可以使用任何语言来实现，上传数据只需要调用相关API即可。Server端负责整体参数调优过程，采Python+Django+Celery技术实现。包括数据特征降维、工作负载匹配、参数调优建议等。



数据库参数自动调优---OTTERTUNE

OtterTune 服务端系统流程图



- 利用相似度算法—欧式距离对待评估系统的工作负载和系统负载资料库中的负载进行匹配，得到最为相似的工作负载数据和对应的数据库参数设置
- 利用降维算法—Lasso Path进行数据库参数特征的降维处理，修剪冗余数据，降低维度。得到最能代表对应的系统负载的参数列表，为后续的参数推荐建议提供依据。
- 利用高斯过程进行数据库参数的设置预测。过程中会加入一些噪声数据，提高预测建议的准确性，最后给出最优的建议设置。

○ 数据库参数自动调优---OTTERTUNE

MySQL数据库负载用TPCC模拟100个仓库的OLTP业务。测试间隔半个小时。数据量10GB。
系统自发现的关键数据库参数：

```
[2019-08-01 12:25:27.757: WARNING/MainProcess] ['innodb_buffer_pool_size', 'innodb_max_dirty_pages_pct', 'thread_cache_size', 'innodb_thread_sleep_delay', 'auto_increment_offset', 'performance_schema_events_statements_history_size', 'performance_schema_events_statements_history_long_size', 'performance_schema_events_stages_history_size', 'performance_schema_events_stages_history_long_size', 'performance_schema_digests_size']
```

系统经过算法学习确定的当前工作负载特征的集群中心20个，对比初始收集的356个系统负载指标相比有大幅度降低。基本和当前的测试负载吻合，随着数据集不断，系统自识别的特征集群会更加完善。

```
[2019-08-01 12:25:27.757: WARNING/MainProcess] cluster number is 15
[2019-08-01 12:25:27.757: WARNING/MainProcess] ['binlog_stmt_cache_size', 'innodb_log_write_requests', 'innodb_data_writes', 'open_tables', 'innodb_buffer_pool_reads', 'innodb_buffer_pool_bytes_dirty', 'innodb_buffer_pool_bytes_data', 'max_used_connections', 'innodb_buffer_pool_pages_total', 'innodb_log_writes', 'uptime', 'innodb_row_lock_current_waits', 'connections', 'innodb_buffer_pool_wait_free', 'innodb_buffer_pool_pages_free', 'innodb_pages_created', 'innodb_data_pending_fsyncs', 'innodb_buffer_pool_pages_flushed', 'innodb_buffer_pool_pages_misc', 'innodb_os_log_pending_fsyncs']
```

系统对待评估系统负载匹配及参数优化设置建议

Workload Mapping

Status:	SUCCESS
Result:	{'scores': [(15, ('oltp_1', 15.63487459103748))], 'mapped_workload_id': (15, 'oltp_1', 15.63487459103748)}

GPR

Status:	SUCCESS
Result:	{'status': 'good', 'recommendation': {'innodb_buffer_pool_size': 671088640.8035482, 'innodb_max_dirty_pages_pct': 50.0, 'innodb_thread_sleep_delay': 373.0, 'performance_schema_events_stages_history_long_size': 10000.0, 'performance_schema_events_stages_history_size': 10.0, 'performance_schema_events_statements_history_long_size': 10000.0, 'performance_schema_events_statements_history_size': 10.0, 'pseudo_thread_id': 10728.999833992417, 'thread_cache_size': 1024.0, 'timestamp': 1565314175.987943}, 'info': 'INFO: training data size is 6'}


时间序列异常值检测---Metis

时间序列异常检测学件的实现思路是基于统计判决、无监督和有监督学习对时序数据进行联合检测。通过统计判决、无监督算法进行首层判决，输出疑似异常，其次进行有监督模型判决，得到最终检测结果。检测模型是经大量样本训练生成，可根据样本持续训练更新。该学件在腾讯的织云企业版本中已覆盖 **20w+** 服务器，承载了 **240w+** 业务指标的异常检测。经过了海量监控数据打磨，该学件在异常检测和运维监控领域具有广泛的应用性。 GitHub地址：<https://github.com/Tencent/Metis>


时间序列异常检测学件

传统阈值监控方式与检测学件作用范围对比。学件作用于数据检测部分，通过学件接口实现智能检测，通过学件支撑系统实现模型迭代演进。

传统阈值检测方式：



学件智能检测方式：



可选配：学件支撑系统（WEB和样本）

异常查看（查询当前检测效果）

标注打标（对数据进行标注，引入运维经验）

样本管理（管理正负样本、管理测试集/训练集）

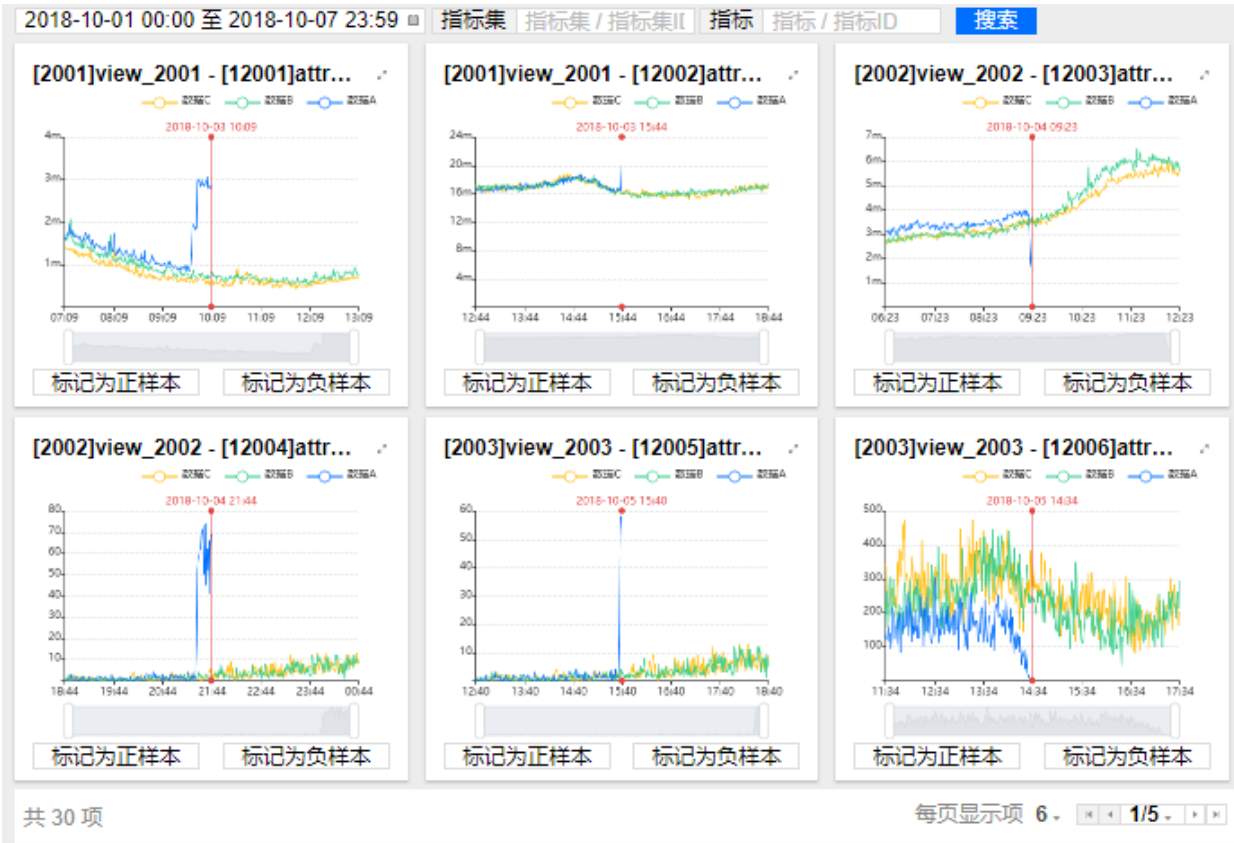
训练模型（新建训练任务、管理检测模型等）

○ 时间序列异常值检测---Metis

时间序列异常检测学件

- 异常检测API：提供率值检测和量值检测API接口，对时间序列进行检测
- 时间序列异常检测学件支撑系统：
 - 特征提取：提供三类特征（统计特征、拟合特征、分类特征）的提取功能，特征维度90+；支持增加自定义特征
 - 异常查询：经API检测后的时间序列（仅异常）入库存储，提供管理功能，分页查询、检索、放缩等
 - 标注打标：提供标注打标的功能，标记/取消标记为正负样本，标记后样本自动转存样本库
 - 样本管理：提供样本管理功能，检索、图示、编辑、删除，导入等功能
 - 模型管理：提供模型管理功能，支持自定义模型训练

异常视图



应用数据场景

- 操作系统数据：适用于检测操作系统层面的基础监控数据，例如CPU、内存、磁盘、流量、包量等。
- 应用程序数据：适用于检测应用程序运行中记录的时序数据，例如读写量、调用量、自定义监控指标等。
- KPI指标数据：适用于检测业务KPI数据，例如交易量、收入值、在线数、成功率、失败量等业务关键指标。

样本库

<input type="checkbox"/>	指标集名称	指标名称	样本来源	时间	训练/...	正/负...	时间窗口(分钟)	操作
<input type="checkbox"/>	demo_17019	demo_37960	Metis	2018-10-03 04:19	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_18545	demo_38441	Metis	2018-10-04 16:37	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_11666	demo_38326	Metis	2018-10-02 18:35	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_12694	demo_36305	Metis	2018-10-03 15:29	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_18472	demo_26550	Metis	2018-10-03 18:08	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_14279	demo_23834	Metis	2018-10-01 16:38	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_15978	demo_39520	Metis	2018-10-06 01:12	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_17052	demo_26099	Metis	2018-10-04 00:32	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_17329	demo_31934	Metis	2018-10-05 19:30	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_15488	demo_21373	Metis	2018-10-05 20:22	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_15451	demo_31064	Metis	2018-10-05 15:47	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_10792	demo_31202	Metis	2018-10-04 14:14	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_17609	demo_22818	Metis	2018-10-04 20:15	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_15668	demo_20482	Metis	2018-10-04 07:01	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_15515	demo_33956	Metis	2018-10-05 18:48	测试集	负样本	180	查看 编辑 删除
<input type="checkbox"/>	demo_10568	demo_28337	Metis	2018-10-04 21:21	测试集	负样本	180	查看 编辑 删除

○ 时间序列异常值检测---应用案例



数据变化量预测：在Oracle表空间数据变化量预测的场景中，对采集的数据应用时间序列异常值检测，当检测到异常值时，将异常值先隔离，用模型在正常的测试数据上进行预测，然后把之前隔离的异常值平摊到预测结果上。



系统异常值的标注：对监控采集的系统性能数据进行异常值检测，准确判断是否产生异常，提高报警的准确性，降低误报率。同时对异常值的特征进行收集、聚类，为将来的系统运行趋势提供数据特征支持，可以提高系统异常检测、预报的准确性。



数据库自动参数调优：通过对数据库性能指标数据进行异常值检测，将异常值隔离，减少对模型训练和参数预测的噪声影响，同时将检测出的异常值输出给监控预警。

谢谢
Thanks

AIOPS-OraDual